

面向 LLM 推理的自进化课程

Xiaoyin Chen^{*,1,2} Jiarui Lu^{1,2} Minsu Kim^{1,3} Dinghuai Zhang^{1,4} Jian Tang^{1,5}

Alexandre Piché⁶ Nicolas Gontier⁶ Yoshua Bengio^{1,2} Ehsan Kamalloo⁶

¹ Mila — 魁北克人工智能研究所, ² 蒙特利尔大学, ³ KAIST, ⁴ 微软研究院, ⁵ HEC 蒙特利尔, ⁶ ServiceNow AI Research

摘要

强化学习 (Reinforcement Learning, RL) 已被证明是微调大语言模型 (Large Language Models, LLMs) 的有效方法, 显著提升了它们在数学、代码生成等领域的推理能力。影响 RL 微调成功与否的一个关键因素是训练课程: 即训练问题呈现的顺序。随机课程作为常见基线仍然次优; 人工设计的课程往往高度依赖启发式规则, 而在线过滤方法则可能带来高昂的计算代价。

为应对这些局限, 我们提出自进化课程 (Self-Evolving Curriculum, SEC) ——一种在 RL 微调过程中与训练并行学习课程策略的自动课程学习方法。我们将课程选择建模为非平稳多臂老虎机 (Multi-Armed Bandit) 问题, 把每个问题类别 (如难度等级或问题类型) 视为单独的臂。我们利用策略梯度方法中的绝对优势值, 作为即时学习增益的代理度量。在每个训练步骤中, 课程策略选择使该奖励信号最大化的类别, 并用 TD(0) 方法进行更新。在规划、归纳推理与数学三个不同的推理领域, 我们的实验表明 SEC 显著提升模型的推理能力, 使其能更好地泛化到更难的分布外测试问题。此外, 当同时微调多个推理领域时, 我们的方法还能实现更好的技能平衡。这些发现凸显 SEC 作为 LLM RL 微调的一种有前景的策略。

1 引言

强化学习 (RL) 已成为微调大语言模型 (LLMs) 的核心技术 (Lightman 等, 2023; OpenAI; DeepSeek-AI, 2025), 显著提升了它们的推理能力。近期进展在验证生成正确性直截了当的领域 (Lambert 等, 2024) ——如数学与代码生成——取得了显著成果。通过仅由可验证结果定义的奖励来优化 LLM, RL 微调鼓励涌现出复杂的推理行为, 包括自我修正与回溯策略 (Kumar 等, 2024; Yeo 等, 2025; Gandhi 等, 2025), 从而大幅提升推理性能。

影响 RL 微调有效性的一个关键因素是训练课程 (Bengio 等, 2009), 即训练数据呈现的顺序。由于在线 RL 本质上依赖于策略模型自身生成高质量训练轨迹, 使课程与模型当前的学习进度对齐至关重要。理想情况下, 这种对齐能使模型




图 1: 课程次序至关重要。精心设计的劣质 (逆向) 课程会严重限制 RL 微调性能; 我们提出的自进化课程 (SEC) 显著优于随机课程。详见 3.1 节。

* 作者于 ServiceNow AI Research 工作期间完成。

¹ 我们的代码公开于 <https://github.com/ServiceNow/sec>。




图 2：自进化课程（SEC）概述。SEC 根据模型当前能力动态调整训练课程。预处理阶段，训练数据被划分为不同类别（以颜色标注），例如按难度等级或问题类型划分。在每个 RL 微调步骤中：（1）课程策略依据各类别的期望学习增益采样训练批次；（2）使用采样批次与选定的 RL 算法更新 LLM 策略；（3）利用 RL 算法估计的优势值计算各课程类别的奖励；（4）相应更新课程策略，以改进后续的数据选择。

持续遇到带来最大学习成效的问题（Schaul 等，2015；Loshchilov 与 Hutter，2015；Katharopoulos 与 Fleuret，2018）。为具体说明这一点，我们用 Countdown 游戏进行了一次受控实验：刻意采用次优的（逆向）课程，按从难到易排列问题。如图 1 所示，所得模型在测试集上表现不佳，对更具挑战性的分布外（OOD）问题几乎没有泛化能力。相比之下，用基线随机课程（各难度问题均匀随机抽取）训练时，模型展现出显著更强的泛化能力与整体任务性能。

尽管随机课程是合理的基线，它自然引发了一个问题：我们能设计更有效的课程策略吗？课程学习（Bengio 等，2009）正是应对这一挑战的，它旨在优化训练任务序列，从而提升学习效率与效果。近期面向 RL 微调的课程学习方法通常包括：预先精心设计的人工课程（Kimi Team 等，2025；Song 等，2025；Wen 等，2025），或基于在线策略样本的动态在线过滤（Yu 等，2025；Bae 等，2025）。然而，人工设计的课程高度依赖启发式规则，每换一个新模型或新任务都需要人工干预；反之，在线过滤方法因持续生成额外的在线策略样本而带来可观的计算开销。

本文提出自进化课程（SEC）（图 2）——一种面向 LLM RL 微调的自动课程学习（Portelas 等，2020）方法。我们的方法在 RL 微调过程中自适应地学习课程策略，将课程选择建模为非平稳多臂老虎机（MAB）问题（Thompson，1933；Sutton 与 Barto，2018；Matiisen 等，2020）。每个课程类别（如难度等级或问题类型）被视为单独的臂，课程策略旨在选择使学习成效最大的臂。我们具体地将“学习成效”用梯度范数来度量，并注意到在策略梯度方法中，梯度范数以优势函数的绝对值为权重。基于这一观察，我们定义绝对优势为每个臂的奖励。在每个 RL 训练步骤中，课程按当前 MAB 策略采样：

² 一种谜题游戏：玩家使用基本算术运算组合给定的一组数字以得到目标数字。

随后用当前训练步骤得到的奖励通过 TD(0) 方法 (Sutton, 1988) 实时更新。

我们的实验表明, SEC 显著提升了模型在三个不同领域——规划、归纳推理与数学——的推理能力, 尤其改善了对富有挑战性的分布外问题的泛化。与标准随机课程相比, SEC 取得了可观的相对提升: Countdown 提升约 13%、Zebra 谜题约 21%、ARC-1D 约 22%, 在 AIME24 数据集上最高达 33%。当跨多个推理领域同时微调时, SEC 有效地平衡了各任务的表现, 凸显了其作为 LLM RL 微调自动课程学习策略的价值。

2 方法

在 RL 微调场景中, 每个训练步骤 t 下, 课程策略从训练问题集 $\mathcal{D}$ 中选取子集 $D_t \subseteq \mathcal{D}$ 提供给 LLM。我们考虑训练问题可归入 N 个不同类别的场景。这一假设将课程优化问题简化为学习一个期望回报 $Q_t(c)$, 它把类别 c 映射为实值分数 (2.1 节)。训练批次随后这样构建: 先按课程策略采样类别, 再在各类别内均匀采样问题。课程策略的目标是最大化 LLM 的最终任务性能。然而, 直接评估该性能需要完成整个 RL 微调过程, 而课程策略更适合随训练步骤同步更新。为解决这一问题, 我们引入一个可局部计算的奖励作为引导课程策略的代理目标 (2.2 节)。

2.1 多臂老虎机形式的课程选择

用于推理任务的训练数据集往往可以自然地分解为不同类别。例如, 如果数据集跨越多个推理领域——数学、编码与规划——这些领域自然形成不同类别。当数据集在任务类型或领域上同质时, 仍可通过基于域内等级 (如难度) 对样本进行归类来构建课程。例如, MATH 数据集 (Hendrycks 等, 2021) 根据 AoPS 提供的指南将问题划分为五个难度等级。此外, 在缺少显式难度标注的情况下, 问题难度可通过训练 LLM 的经验准确率来估计, 或借助额外的预处理步骤提示专家 LLM (如 Shi 等, 2025 所示)。

基于上述考虑, 我们假设——特别是对以推理为主的数据集——训练问题可划分为 N 个不同类别 $\mathcal{C} = \{c_1, c_2, \dots, c_N\}$ 。概念上, 课程策略优化问题可视为部分可观测马尔可夫决策过程 (POMDP): 状态为当前 LLM 策略, 动作为课程选择, 奖励由可观测的性能指标定义, 如与所选课程相关的在线策略性能。

这种 POMDP 表述天然类似于非平稳 MAB 问题 (Matiisen 等, 2020 也指出这一点): 每个臂表示一个问题类别 c_i , 目标是在训练步骤 t 学习与选择类别 c 相关联的期望回报 $Q_t(c)$ 。重要的是, 此处的 MAB 是非平稳的: 随着 LLM 策略在训练过程中被更新, 每个臂的期望奖励分布也在漂移。为解决这一经典的非平稳老虎机问题 (Thompson, 1933; Sutton 与 Barto, 2018), 我们采用经典的 TD(0) 方法 (Sutton, 1988) 迭代更新 $Q_t(c)$:

$$Q_{t+1}(c) = \alpha r_t(c) + (1 - \alpha) Q_t(c) \quad (1)$$

其中 α 为学习率, $Q_0(c) = 0$ 将分数初始化为零, $r_t(c)$ 表示下一节定义的奖励。注意这也就是指数移动平均。课程策略可简单地基于 $Q_t(c)$ 定义, 详见 2.3 节。

理想的课程应使 LLM 在整个训练周期之后的测试数据上最终性能最大化。然而，直接度量该目标需要完成整个 RL 微调循环。尽管评估中间检查点能部分缓解这一问题，但频繁评估的计算代价高昂。为克服这一挑战，我们引入一个可在每个训练步骤高效局部计算的代理目标。

这类代理目标的一个直观选择是优先训练能最大化模型即时学习成效的数据（Schaul 等, 2015; Loshchilov 与 Hutter, 2015; Katharopoulos 与 Fleuret, 2018），即能引发较大参数更新的数据。实践上，这可以通过度量损失函数关于所选训练数据的梯度范数来量化。具体而言，考虑一个策略梯度算法，它通过最小化以下损失函数优化 LLM 策略：

$$\mathcal{L}_{\text{PG}}(\theta) = -\mathbb{E}_{(s_t, a_t) \sim \pi_\theta} \left[\log \pi_\theta(a_t | s_t) \hat{A}_t \right] \quad (2)$$

其中 π_θ 表示 LLM 策略， $\hat{A}_t$ 表示优势值。那么每一步 (s_t, a_t) 的梯度范数为：

$$\|\nabla_\theta \mathcal{L}_{\text{PG}}(\theta, s_t, a_t)\|_2 = \left\| \mathbb{E}_{(s_t, a_t) \sim \pi_\theta} \left[\nabla_\theta \log \pi_\theta(a_t | s_t) \hat{A}_t \right] \right\|_2 \approx |\hat{A}_t| \|\nabla_\theta \log \pi_\theta(a_t | s_t)\|_2$$

我们观察到梯度幅值以优势值的绝对值 $|\hat{A}_t|$ 为权重。因此，我们用 $|\hat{A}_t|$ 的批次期望近似课程 c 的学习增益：

$$r(c) = \mathbb{E}_{(s_t, a_t) \sim \pi_\theta(x_i), x_i \sim c} \left[|\hat{A}_t| \right] \quad (3)$$

换言之，每个训练步骤中课程 c 的奖励，等于从课程类别 c 中抽取问题所关联的所有采样轨迹上的平均绝对优势。

2.3 面向 RL 微调的自进化课程

每个 RL 训练步骤中，按以下方式生成问题批次。首先，依据当前 $Q_t(c)$ 值按 Boltzmann 分布采样类别：

$$p(c) = \frac{e^{Q_t(c)/\tau}}{\sum_{i=1}^N e^{Q_t(c_i)/\tau}}$$

其中 τ 是控制探索-利用权衡的温度参数。其次，从选中的类别中均匀采样问题。该过程重复进行，直到达到期望批次大小。从 Boltzmann 分布采样天然地在课程选择中平衡探索与利用。

所得批次随后用于更新 LLM 策略。在每步策略更新之后，我们计算每个采样类别 c 的奖励 $r(c)$ ，并用等式 1 更新相应的 $Q_t(c)$ 值。SEC 的完整过程总结于算法 1。

3 实验

本节展示评估 SEC 的三个推理领域实验：规划、归纳推理与数学。我们另外考察 SEC 在不同课程类别与替代 RL 算法下的有效性。

3.1 实验设置

我们使用开源权重的 Qwen2.5 模型（Yang 等, 2024）：Qwen2.5-3B 与 Qwen2.5-7B。推理任务的 RL 微调采用广泛使用的 GRPO 算法（Shao 等, 2024; DeepSeek-AI, 2025）。我们报告最佳检查点的平均 pass@1 准确率，按每个问题 8 次独立生成计算。其他训练与评估细节见附录 C。所有任务的提示词与数据示例见附录 D。

我们的实验覆盖了三个需要不同能力的推理领域：（i）规划，需要前瞻搜索与回溯；（ii）归纳推理，涉及从观察中学习一般规则并将其应用于未见场景；（iii）数学，需要多步逻辑推理与系统性的问题求解。

Algorithm 1 SEC: RL Fine-tuning with Self-evolving Curriculum

Require: Training set D partitioned into categories $C = \{c_1, \dots, c_N\}$; LLM policy π_θ with parameters θ ; Learning rate α (for Q updates); Temperature τ ; Batch size B ; Total training steps T ; Reward function $\mathcal{R}$; RL algorithm $\mathcal{A}$

```
1: Initialize  $Q_0(c) \leftarrow 0 \ \forall c \in C$ 
2: for  $t \leftarrow 0$  to  $T - 1$  do
3:    $B_t \leftarrow \emptyset$ 
4:   while  $|B_t| < B$  do
5:     Sample category  $c \sim \text{Softmax}(Q_t(c)/\tau)$ 
6:     Sample problem  $x$  uniformly from category  $c$ 
7:      $B_t \leftarrow B_t \cup \{x\}$ 
8:   end while
9:   Run  $\pi_\theta$  on each  $x \in B_t$  to generate rollouts  $\mathcal{T}$  and compute rewards  $\mathbf{r}$  with  $\mathcal{R}$ 
10:  Estimate advantages  $\hat{A}$  and update  $\pi_\theta$  with  $\mathcal{A}(\pi_\theta, \mathcal{T}, \mathbf{r})$ 
11:  for all  $c \in C$  do
12:     $B_c \leftarrow \{x \in B_t \mid x \text{ belongs to category } c\}$ 
13:     $r_t(c) \leftarrow \frac{1}{|B_c|} \sum_{j: x_j \in B_c} \frac{1}{T_j} \sum_t^{T_j} |\hat{A}_{t,j}|$ 
14:     $Q_{t+1}(c) \leftarrow \alpha r_t(c) + (1 - \alpha) Q_t(c)$ 
15:  end for
16: end for
17: return Fine-tuned LLM  $\pi_\theta$ 
```

规划。对于规划任务，我们考虑两个流行的谜题问题：（i）Countdown，目标是从给定 3–6 个整数中，使用基本算术运算得到目标数字。该谜题中，我们通过增加给定整数的个数来控制难度。（ii）Zebra 谜题，一个包含 3–6 个实体（如房子）、每个实体有 3–6 个属性（如颜色）的经典逻辑谜题。给定一组文本线索（约束），目标是正确地为每个实体分配每个属性。这里，我们通过增加实体与属性的数量来控制任务难度。

归纳推理。我们采用抽象与推理语料（ARC）的 1D 变体（Chollet, 2019; Xu 等, 2023）。每个谜题实例由长度为 10、20、30 或 40 的字符串组成（长度越大难度越高），其元素为整数。给出三个说明潜在规则的输入-输出示例，LLM 需在一个未见用例上进行泛化测试。

对上述三个推理任务（Countdown、Zebra 与 ARC），我们使用 Open-Thought（2025）提供的框架生成问题。具体而言，训练数据包含三个最简单难度等级，最难的等级保留为分布外（OOD）评估集。每个难度等级采样 10,000 个训练问题与 200 个留出评估样本。RL 微调期间，答对奖励 1、答错但格式正确奖励 0.1、其余为 0。

数学。我们在 MATH 数据集（Hendrycks 等, 2021）的训练划分上训练 LLM，其问题按数据标注分为五个难度等级，从 1（最易）到 5（最难）。与前三个任务不同，数学任务训练数据在这些难度等级间是不平衡的（图 S1）。该任务使用二值奖励（正确为 1、否则为 0），不给正确格式赋部分奖励。模型随后在 MATH500、AMC22–23 与 AIME24 数据集上评估。

3.2 主要结果

首先，我们用问题难度作为课程类别评估 SEC 的有效性，即每个难度等级对应 MAB 框架中的一个臂。我们将 SEC 与两种常用课程策略比较：（1）随机/无课程，训练样本按原始数据分布均匀抽取自所有难度等级，对应常规“无课程”方法；（2）难度有序课程，问题

表 1：跨推理任务与课程方法的评估。准确率按每个问题 8 次独立生成的平均 pass@1 计算。分布内（ID）结果取训练所用三个难度等级同分布的测试问题的平均。各数据集与模型尺寸下最优课程策略以粗体显示，次优的加下划线。SEC 在各任务上表现持续出色，尤其提升了挑战性 OOD 测试问题的泛化。

averaged over test problems sampled from the same three difficulty levels used in training. The best-performing curriculum strategy for each dataset and model size is shown in **bold**, and the second-best is underlined. SEC consistently achieves strong performance across tasks, particularly improving generalization on challenging OOD test problems.

Task	Split	Qwen2.5 3B			Qwen2.5 7B		
		Random	Ordered	SEC (Ours)	Random	Ordered	SEC (Ours)
<i>Countdown</i>	ID	<u>0.859</u>	0.551	0.866	<u>0.858</u>	0.820	0.872
	OOD	<u>0.479</u>	0.321	0.542	<u>0.566</u>	0.442	<u>0.555</u>
<i>Zebra</i>	ID	0.517	<u>0.534</u>	0.547	<u>0.573</u>	0.572	0.587
	OOD	0.285	<u>0.329</u>	0.345	<u>0.321</u>	0.311	0.355
<i>ARC-1D</i>	ID	0.501	0.476	0.500	0.512	0.526	<u>0.514</u>
	OOD	0.313	<u>0.363</u>	0.381	0.436	<u>0.428</u>	0.418
<i>Math</i>	MATH500	0.668	0.672	0.672	0.774	0.759	<u>0.761</u>
	AMC22-23	0.345	0.352	0.351	<u>0.486</u>	0.477	0.511
	AIME24	<u>0.075</u>	0.054	0.100	0.138	<u>0.150</u>	0.175

按从易到难依次呈现。SEC 在所有实验设置下的超参数详见附录 C。

表 1 汇总的结果展现了 SEC 跨任务与模型的明显优势。对较小的 Qwen2.5-3B 模型，SEC 在更难的分布外（OOD）测试集上持续取得显著提升。具体而言，Countdown 上 SEC 将 OOD 准确率较随机基线相对提升约 13%（0.48 → 0.54），较难度有序基线相对提升约 69%（0.32 → 0.54）。类似地，Zebra 上 SEC 较随机获得约 21% 的相对提升（0.29 → 0.35）。数学方面，SEC 使挑战性 AIME 数据集的性能较随机基线相对提升约 33%（0.075 → 0.10）。

对更大的 Qwen2.5-7B 模型，SEC 的表现具有竞争力，但在 Countdown、ARC 等任务上与随机课程更为接近。这一结果符合预期：更强的基础模型可能已经具备足够的推理能力来处理更难的问题，因此显式课程引导的边际收益较低。尽管如此，在 Zebra 与数学等更具挑战性的任务上，SEC 仍显现出明显改进：Zebra 的 OOD 准确率较随机基线相对提升约 11%（0.32 → 0.36）；在挑战性的 AIME 问题上，SEC 获得 27% 的相对增益（0.14 → 0.18）。这些更具挑战性领域中的一致改进，加上 3B 模型上的稳健收益，凸显了 SEC 在提升模型泛化方面的有效性。

对更大的 Qwen2.5-7B 模型，SEC 的表现仍具竞争力，但在 Countdown 与 ARC 等任务上与随机课程差异不大。这一结果同样符合预期：更强的基座模型通常已具备应对广泛问题的推理能力，从而降低了显式课程的边际收益。然而，在 Zebra 与数学等更具挑战性的领域，SEC 依旧带来明显增益——例如 Zebra OOD 相对提升约 11%（0.32 → 0.36），AIME 相对提升 27%（0.14 → 0.18）。

为检验课程收益是否随任务难度提升而重新显现，我们在更难的 Countdown 变体上评估 Qwen2.5-7B（以规模 4-6 训练，规模 7 作为 OOD 评估；此前为 3-5 训练、6 为 OOD）。如表 2 所示，SEC 在 ID 与 OOD 上再次优于随机，证实当任务变得更难时，课程收益对大模型依然存在。

最后，难度有序课程往往导致次优性能，这很可能因为它固定的难度调度无法根据模型当前表现动态调整。结果，模型可能把过多训练时间花在容易的问题上，从而减少接触那些可能带来更多学习收益的难题。这些结果进一步凸显了像 SEC 这样自适应、在线的课程策略的必要性——它持续将问题选择与模型当前的学习状态对齐。




图 3：训练步骤中的平均采样难度。SEC 在 RL 微调期间自适应调整任务难度。蓝色曲线表示采样难度（移动平均平滑），绿色虚线表示数据集平均难度。在所有基准（列）与模型尺寸（上排：Qwen2.5-3B，下排：Qwen2.5-7B）上，SEC 起初选择较易的问题，随训练推进逐步引入更难的问题，使难度与模型改进有效对齐。

课程分析。图 3 展示了 SEC 如何在任务与模型间自适应地调整训练难度。对每个任务与模型，采样难度（蓝色曲线）起初低于或接近数据集平均难度（绿色虚线），表明 SEC 初期侧重易题以促进早期学习。随着训练推进，SEC 逐步提高所选问题的难度，使训练复杂度与模型不断改进的能力对齐。值得注意的是，对更强的 Qwen2.5-7B，SEC 选择了比 3B 模型更难的题目，进一步证实 SEC 能根据模型的学习能力有效调整课程。这种跨任务与模型的自适应模式，凸显了 SEC 动态调整问题难度以最大化学习成效的优势。

3.3 具有多种课程类别的 SEC

本节展示 SEC 可无缝支持同时从多个多样化的课程类别中采样。RL 微调中的常见场景是在多个推理领域上优化模型性能。为在多任务设定下评估 SEC，我们将 Countdown、Zebra 与 ARC 的训练数据集合并，构建一个包含多种推理问题的混合训练集，并用 Qwen2.5-3B 模型进行 RL 微调。目标是获得在所有推理任务上的强整体性能。

我们的基于 MAB 的课程框架不依赖课程类别的语义含义，因此类别可以任意定义。本实验中，我们为 3 种问题类型与 3 种难度等级的每种唯一组合定义一个臂，共 9 个不同臂。我们将该变体记为 SEC-2D。

图 4 给出了同时多任务训练时 SEC-2D 的评估结果。左侧表格表明，SEC-2D 在全部三个推理任务上均一致优于随机课程。右侧学习曲线详细展示了 Countdown OOD 准确率随训练推进的变化。起初两种课程都快速提升；然而随机课程在训练中途出现明显性能崩溃，凸显其无法有效平衡多任务学习。相比之下，SEC-2D 保持稳定、稳健的性能，彰显了其自适应平衡多个学习目标的能力。

SEC-2D 保持稳定、稳健的性能，凸显其在自适应平衡多个学习目标方面的优势。

表 2：Qwen2.5-7B 在更难的 Countdown 变体上。当任务更具挑战性时，SEC 重新相对于随机取得明显增益。

Method	ID	OOD
Random	0.654	0.373
SEC	0.686	0.439

表 3：使用替代 RL 算法的 SEC。与随机课程相比，SEC 提升了不同 RL 算法（PPO、RLOO）下的 RL 微调性能。

RL Method	Split	Random	SEC
PPO	ID	0.621	0.750
	OOD	0.159	0.224
RLOO	ID	0.821	0.859
	OOD	0.465	0.494

Task	Split	Random	SEC-2D
Countdown	ID	0.837	0.839
	OOD	0.418	0.428
Zebra	ID	0.513	0.539
	OOD	0.254	0.312
ARC	ID	0.380	0.418
	OOD	0.251	0.327




图 4：多任务同时训练时的性能比较。左：Qwen2.5-3B 在 ID 与 OOD 划分上的测试准确率。SEC-2D 通过为“问题类型 $\times$ 难度等级”的每种组合定义一个臂来实现。SEC-2D 始终取得更高准确率，相比随机课程在任务间表现出更强的泛化。右：Countdown OOD 准确率随训练步数的变化（移动平均平滑）。随机课程的性能在训练中途崩溃，凸显其无法有效平衡多任务；相比之下 SEC-2D 全训练过程保持稳定。

3.4 配合替代 RL 算法的 SEC

虽然我们的主实验采用 GRPO 算法，我们还使用其他广泛使用的 RL 方法评估 SEC，具体为近端策略优化 (PPO) (Schulman 等, 2017) 与 REINFORCE Leave-One-Out (RL00) (Kool 等, 2019)。表 3 给出 Qwen2.5-3B 在 Countdown 任务上的结果，比较这两种算法下 SEC 与随机课程。在 PPO 与 RL00 下，SEC 均一致提升 ID 与 OOD 评估划分的性能，证明其有效性不限于单一 RL 算法。

3.5 使用自动推断课程类别的 SEC

虽然主实验使用由元数据预定义的课程类别，SEC 并非总是需要人工整理。为证明这一点，我们使用 Shi 等 (2025) 发布的数学问题数据集，它由 Qwen2.5-MATH-7B 采样估计得到每个问题的经验成功率。我们将这些成功率离散化为 k 个等宽箱以创建课程类别（报告 $k = 3$ 与 $k = 5$ 的结果），同时保持 RL 设置、课程奖励与采样策略不变。

表 4 显示 MATH500、AMC22-23 与 AIME24 上的结果：SEC 两个变体在三项数学基准上均优于随机；说明 SEC 可利用自动推断的课程类别，减少对人工标签的依赖。

表 4：使用自动推断课程类别的数学任务。当课程类别由经验成功率而非人工标签推导时，SEC 仍然有效。

MATH500	AMC22-23	AIME24
0.654	0.312	0.080
0.664	0.389	0.088
0.671	0.358	0.083

4 相关工作

语言模型的 RL 微调。语言模型 (LM) 天然可视为序列决策策略：基于部分文本状态生成词元，直至到达终止输出。通常奖励信号稀疏且是情节式的，只在完整生成后给出，这类方法称为结果奖励模型 (ORM) (Cobbe 等, 2021)。一些近期研究引入过程奖励模型 (PRM)，在生成过程中分配中间奖励以促进局部信用分配 (Lightman 等, 2023; Uesato 等, 2022)。借助这一马尔可夫决策过程 (MDP) 框架，RL 微调已在多个领域取得成功：包括让 LM 与人类偏好对齐 (RLHF) (Christiano 等, 2017; Ziegler 等, 2019; Bai 等, 2022; Ouyang 等, 2022)、通过精确匹配奖励增强数学推理 (Shao 等, 2024)，以及利用 LM 内部分布的自我训练 (如自我推理教者 STaR) (Zelikman 等, 2022)。近期，可验证奖励强化学习 (RLVR) (DeepSeek-AI, 2025; Lambert 等, 2024) 已成为提升 LM 推理能力的有前景的范式。

针对这些 MDP 公式定制的 RL 方法同样发挥了核心作用。策略梯度方法——包括 REINFORCE 变体（如 RL00）（Williams, 1992; Kool 等, 2019; Ahmadian 等, 2024）与近端策略优化（PPO）方法（Schulman 等, 2017; Shao 等, 2024）——因其相对稳定而被广泛采用。另一方面，异策略与基于价值的方法，如直接偏好优化（DPO）（Rafailov 等, 2023; Meng 等, 2024）与生成流网络（GFlowNets）（Bengio 等, 2021; Hu 等, 2024; Ho 等, 2024），在样本效率、多样性与异步训练方面具有优势（Noukhovitch 等, 2024; Bartoldson 等, 2025），尽管它们在最大化任务特定奖励方面可能不如在线策略方法，而优先考虑提升多样性。

课程学习。课程学习由 Bengio 等（2009）提出，后经自步学习（Kumar 等, 2010）细化，表明按从易到难组织样本能平滑非凸优化并提升泛化。在 RL 中，课程能缓解稀疏奖励与探索障碍：逆向课程生成从目标状态向外扩展起始状态（Florensa 等, 2017）；师生课程学习（TSCL）（Matiisen 等, 2020）也用非平稳 MAB 框架最大化实测学习进展，其定义为任务性能的改进；POET、ACCEL 与 PAIRED 等方法让任务与智能体协同进化（Wang 等, 2019; Parker-Holder 等, 2022; Dennis 等, 2020）；Kim 等（2025）提出一种自适应教师，为多模态摊销采样动态调整课程。

直到最近，类似的课程学习思想才开始影响语言模型的 RL 微调。R3 将逆向课程专门用于思维链推理，基于黄金演示逐步揭示更长的推理序列（Xi 等, 2024）。Qi 等（2024）提出 WEBRL——一个用于训练基于 LM 的智能体的自进化在线课程 RL 框架，通过提示另一 LLM 基于先前失败自主生成新任务。PAPRIKA（Tajwar 等, 2025）也采用 MAB 公式，从多样化的决策问题中选择训练任务组，增强 LLM 智能体策略信息收集的能力。

与此同时，若干研究探索了 RL 微调的自动课程学习。Bae 等（2025）提出通过反复生成解来估计问题难度的在线过滤。AdaRFT（Shi 等, 2025）根据模型近期奖励信号自适应调整课程难度，但依赖显式的难度等级排序。相比之下，SEC 用通用的 MAB 公式动态调整课程。DUMP（Wang 等, 2025b）与本文并行，同样以绝对优势作为课程奖励并用 MAB 框架。

5 结论

本文提出了自进化课程（SEC）——一个面向 LLM RL 微调的自动课程学习框架。SEC 将自适应课程选择建模为非平稳多臂老虎机问题，根据模型不断演进的能力动态调整问题难度。跨规划、归纳推理与数学等多样推理任务的广泛实验表明，SEC 一致提升泛化能力，并能同时有效平衡多个推理领域间的学习。

我们的框架由三个主要组件构成：课程奖励、采样方法与更新规则。本文中，SEC 采用绝对优势作为课程奖励、Boltzmann 分布进行采样、TD(0) 方法进行更新。这些组件的泛化可作为未来工作探索。例如，可以借助上界置信区间（UCB）（Auer, 2002）或 Thompson 采样（Thompson, 1933）等方法，将不确定性度量纳入课程选择。

局限性。尽管 SEC 在多样推理任务上表现出稳定的有效性，它仍有一些局限。SEC 引入了需要调优的额外超参数（如温度、学习率）。未来工作可探索更灵活的课程定义，例如基于嵌入对问题进行聚类，或用轻量模型（如线性回归）直接估计课程奖励。

致谢

我们感谢 Dzmitry Bahdanau 与 Nicolas Chapados 的深入讨论与对本项目的帮助。作者感谢 CIFAR、NSERC 与未来生命研究所的资助。Minsu Kim 获 KAIST Jang Yeong Sil 奖学金支持。

附录 A 可验证奖励 RL 中绝对优势的解

近期针对推理任务的 RL 微调工作常采用二值正确性奖励（错为 0、对为 1）配合群体相对策略优化（GRPO）算法（Shao 等，2024；Kumar 等，2024；DeepSeek-AI，2025；Luo 等，2025；Wei 等，2025），该设置称为可验证奖励 RL（Lambert 等，2024）。在此常见设置下，我们证明：如等式 3 所形式化的期望绝对优势，在期望二值奖励为 0.5 时取最大值。这意味着当问题对当前模型既不太易也不太难得恰到好处时，学习增益最大。优先训练这类难度的问题，与教育心理学的概念天然相符，特别是最近发展区理论（Vygotsky 与 Cole，1978；Chaiklin 等，2003），并使我们的方法能与课程学习中更广泛的文献相连（Florensa 等，2017；2018；Tzannetos 等，2023；Bae 等，2025）。

具体来说，GRPO 算法通过从同一问题采样 n 个采样路径来估计优势。第 i 个采样路径的优势计算为： $\hat{A}_{t,i} = \tilde{r}_i = \frac{r_i - \text{mean}(r)}{\text{std}(r)}$ ，其中 r_i 是第 i 个采样路径的二值奖励， $\text{mean}(r)$ 与 $\text{std}(r)$ 表示全部 n 个采样路径奖励的均值与标准差。由于奖励是二值的，可建模为伯努利分布：因此 $\text{mean}(r) = p$ 、 $\text{std}(r) = \sqrt{p(1-p)}$ ，其中 p 表示成功率。期望绝对优势可表达为：

$$\mathbb{E}[|\hat{A}_{t,i}|] = \mathbb{E}[|\tilde{r}_i|] = \mathbb{E}\left[\left|\frac{r_i - p}{\sqrt{p(1-p)}}\right|\right] \quad (4)$$

由于 r_i 服从伯努利分布，只有两种可能取值：

$$\tilde{r}_i = \begin{cases} \frac{1-p}{\sqrt{p(1-p)}} & \text{以概率 } p \\ \frac{-p}{\sqrt{p(1-p)}} & \text{以概率 } 1-p \end{cases} \quad (5)$$

因此，该问题的期望绝对优势为：

$$\mathbb{E}[|\tilde{r}_i|] = p \cdot \frac{1-p}{\sqrt{p(1-p)}} + (1-p) \cdot \frac{p}{\sqrt{p(1-p)}} = \frac{2p(1-p)}{\sqrt{p(1-p)}} = 2\sqrt{p(1-p)} \quad (6)$$

可以看出函数 $g(p) = 2\sqrt{p(1-p)}$ 关于 $p = 0.5$ 对称，且在区间 $[0, 1]$ 上严格凹，在 $p = 0.5$ 处取得最大值。这一推导表明，最大化期望绝对优势等价于优先处理成功率为 0.5 的问题。

备注：上述推导旨在为常见 RL 微调设置下我们提出的目标提供具体分析，并对其一般行为给出直觉理解。然而，这并不意味着我们的方法仅限于这一特定场景。事实上，我们的实验表明，SEC 在非二值奖励函数（3.2 节）与替代 RL 算法（3.4 节）下同样表现强劲。

附录 B 跨基础模型家族的 SEC

为考察 SEC 是否超越 Qwen2.5 家族泛化，我们对 Wang 等（2025a）发布的 Llama-3.2-1B 变体（经特殊中期训练以提升 RL 微调性能）进行微调。如表 S1 所示，在 Countdown 任务上，SEC 在两个划分上都优于随机课程，表明我们的方法跨模型家族与规模泛化。

附录 C 实现细节

训练。所有模型均以 GRPO 算法（Shao 等，2024）微调，实现采用火山引擎强化学习（verl）库（Sheng 等，2024）。我们分别训练

表 S1: Llama-3.2-1B 在 Countdown 上。SEC 在 ID 与 OOD 上均优于随机，表明该方法在单一模型家族之外依然泛化。

Method	Countdown ID	Countdown OOD
Random	0.758	0.192
SEC	0.776	0.265

Qwen2.5 (Yang 等, 2024) 的 3B 与 7B 参数变体。微调过程在三个谜题任务上, Qwen2.5-3B 共进行 240 个梯度步、Qwen2.5-7B 120 步, 批大小为 256。优势由 8 个采样路径估计。两个模型在数学任务上训练 240 步。我们在全部研究中将 KL 散度损失权重设为 0, 即不施加 KL 散度损失。最大提示长度限制为 1,024 个词元, 最大回复长度 4,096 个词元。模型参数用 Adam (Kingma 与 Ba, 2014) 优化, 学习率 $1e-6$, beta (0.9, 0.99), 无预热步骤。所有训练实验在 4-8 块 NVIDIA H100 80GB GPU 上进行。每个实验使用的 SEC 超参数汇总于表 S2。

Model	Countdown	Zebra	ARC	Math
Qwen2.5 3B	$\alpha = 0.5, \tau = 1.0$	$\alpha = 0.5, \tau = 1.0$	$\alpha = 0.5, \tau = 1.0$	$\alpha = 0.2, \tau = 1.0$
Qwen2.5 7B	$\alpha = 0.5, \tau = 0.2$	$\alpha = 0.5, \tau = 0.4$	$\alpha = 0.5, \tau = 1.0$	$\alpha = 0.5, \tau = 0.4$

表 S2: 各实验使用的超参数设置 (学习率 α 与温度 τ)。

对于 3.3 节的多任务实验, 我们在混合数据集上微调 Qwen2.5-3B 共 $3 \times 240 = 720$ 步, 使用 $\alpha = 0.5$ 、 $\tau = 0.2$ 。

在 3.4 节中, 我们在所有实验里训练 Qwen2.5-3B 120 步。对 RL00, 我们同样使用 8 个采样路径进行优势估计, SEC 取 $\alpha = 0.5$ 、 $\tau = 0.25$ 。对 PPO, SEC 用 $\alpha = 0.5$ 、 $\tau = 1$, GAE 参数 $\lambda = 1$ 、 $\gamma = 1$ 。与主实验一致, 我们不施加 KL 散度损失。

模型。下面列出实验中使用的模型:

- Qwen2.5-3B: <https://huggingface.co/Qwen/Qwen2.5-3B>
- Qwen2.5-7B: <https://huggingface.co/Qwen/Qwen2.5-7B>

数学数据集。下面列出实验中使用的数据来源:

- MATH500: <https://huggingface.co/datasets/HuggingFaceH4/MATH-500>
- AMC22-23: <https://huggingface.co/datasets/AI-MO/aimo-validation-amc>
- AIME: https://huggingface.co/datasets/Maxwell-Jia/AIME_2024

附录 D 数据示例

下面列出每个任务的提示词与数据示例。提示词模板采用 Pan 等 (2025)。

Prompt for Countdown:

A conversation between User and Assistant. The user asks a question, and the Assistant solves it. The assistant first thinks about the reasoning process in the mind and then provides the user with the answer.

User: Using the numbers [5, 17, 91], create an equation that equals




图 S1: MATH 训练集中难度等级的分布。

113. You can only use basic arithmetic operations (+, -, *, /) and each number should be used exactly once. Return the final answer in `\boxed{}`, for example `\boxed{(1 + 2) / 3}`. Assistant: Let me solve this step by step.

Prompt for Zebra Puzzle:

A conversation between User and Assistant. The user asks a question, and the Assistant solves it. The assistant first thinks about the reasoning process in the mind and then provides the user with the answer.

User: This is a logic puzzle. There are 3 houses (numbered 1 on the left, 3 on the right), from the perspective of someone standing across the street from them. Each has a different person in them. They have different characteristics:

- Each person has a unique name: arnold, bob, alice
- Everyone has a different favorite cigar: dunhill, prince, pall mall
- The people keep different animals: cat, dog, bird

1. The bird keeper is directly left of the Dunhill smoker.
2. Alice is the dog owner.
3. Arnold is in the second house.
4. Alice is the Prince smoker.
5. Arnold is the cat lover.

What is Name of the person who lives in House 1? Provide only the name of the person as your final answer and put in in `\boxed{}`, for example: `\boxed{Alice}`. Assistant: Let me solve this step by step.

Prompt for ARC-1D:

A conversation between User and Assistant. The user asks a question, and the Assistant solves it. The assistant first thinks about the reasoning process in the mind and then provides the user with the answer.

User: Find the common rule that maps an input grid to an output grid, given the examples below.

Example 1:

Input: 1 2 1 2 1 0 0 1 2 0

Output: 0 0 0 1 1 1 1 2 2 2

Example 2:

Input: 1 2 0 0 0 0 2 0 1 2

Output: 0 0 0 0 0 1 1 2 2 2

Example 3:

Input: 0 0 2 0 0 0 0 1 1 0

Output: 0 0 0 0 0 0 0 1 1 2

Below is a test input grid. Predict the corresponding output grid by applying the rule you found. Describe how you derived the rule and your overall reasoning process in detail before you submit your answer. Your final answer must be placed in `\boxed{}` and should be just the test output grid itself.

Input: 0 0 2 0 0 1 1 0 0 1 Assistant: Let me solve this step by step.

Prompt for math:

A conversation between User and Assistant. The user asks a question, and the Assistant solves it. The assistant first thinks about the reasoning process in the mind and then provides the user with the answer.

User: Find the remainder when

$$33818^2 + 33819^2 + 33820^2 + 33821^2 + 33822^2$$

is divided by 17. Put your final answer within `\boxed{}`. Assistant: Let me solve this step by step.